Tradução PT-BR — Capítulo 7

Arquivo original: TG2_Bruno_Silveira.pdf

Capítulo traduzido: 7 Conclusion (Conclusão).

7 CONCLUSÃO

Este trabalho apresentou o desenvolvimento do B.A.L.A.S, uma ferramenta que pode ser utilizada para benchmarking automatizado de latência de ANNs em microcontroladores reais, e que pode ser estendida e adaptada para suportar outros MCUs ao se reimplementar as etapas de compilação e deploy, bem como as funcionalidades de temporizador e UART. Demonstrou-se que o B.A.L.A.S possui alta compatibilidade com variações de modelos padrão de benchmarking de TinyML, embora a ferramenta escolhida para estimativa de tensor arena (stm32tflm) falhe em alguns modelos. Assim, encontrar outro método de estimativa de tensor arena que funcione em 100% dos modelos testados é um ponto claro de melhoria para esforços futuros de pesquisa e desenvolvimento.

Além disso, os experimentos mostraram que tanto o número de MACs quanto o tempo de inferência na CPU da estação de trabalho, quando usados como métricas proxy para a latência real de inferência no MCU, podem ser pouco confiáveis, exibindo erros de pior caso que poderiam guiar o processo de busca para um caminho subótimo. Isso ressalta a importância de usar uma ferramenta como o B.A.L.A.S e medir a latência de inferência no dispositivo quando baixa latência é crítica para a aplicação TinyML-alvo. Também foi mostrado que, com otimizações adequadas no processo, é possível medir o tempo real de inferência em hardware na ordem de 20 segundos por modelo, o que é significativamente menor do que o tempo necessário para treinar um modelo, mesmo que parcialmente. Isso questiona o argumento de que o profiling no dispositivo leva tempo demais, corroborando o trabalho de (TAN et al., 2019) e compartilhando dados valiosos de tempo com a comunidade de pesquisa em TinyML.

À luz desses resultados, defende-se um fluxo de trabalho para processos de NAS voltados a otimização de latência em TinyML. Na primeira etapa, quando o espaço de busca ainda é amplo, proxies rápidos de latência, como número de MACs e tempo de inferência na estação de trabalho, podem ser usados para economizar tempo, pois apresentam correlação positiva com o tempo real de inferência. Em seguida, em uma segunda e última etapa, quando o espaço de busca está mais estreito, pode-se substituir o proxy por medições reais automatizadas. Isso garante que a busca não seja afetada negativamente pelas imprecisões imprevisíveis dos proxies, que se tornam mais aparentes em comparações mais próximas.

Para trabalhos futuros que expandam esta pesquisa, além de melhorar a compatibilidade da estimativa de tensor arena, os mesmos experimentos e análises poderiam ser realizados usando o acelerador NPU do microcontrolador, explorando se isso aumenta ou reduz a qualidade das estimativas por proxy. Além disso, uma linha de pesquisa interessante seria usar o B.A.L.A.S e o fluxo de trabalho proposto para executar uma busca real para uma tarefa TinyML, comparando os resultados finais do modelo com buscas realizadas apenas usando proxies. Isso serviria como exemplo claro de quanto ganho de desempenho pode ser esperado ao usar esse método em tarefas TinyML reais.